



中山大學
SUN YAT-SEN UNIVERSITY

本科生毕业论文（设计）

Undergraduate Graduation Thesis (Design)

题目：层叠成像中的相位恢复问题

院系

School(Department): 数学学院

专业

Major: 数学与应用数学

学生姓名

Student Name: 吴苘

学号

Student No: 17307053

指导教师（职称）

Supervisor(Title): 李嘉

时间：二零二二年四月十一日

Date: April 11th 2022

学术诚信声明

本人所呈交的毕业论文，是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料均真实可靠。除文中已经注明引用的内容外，本论文不包含任何其他人或集体已经发表或撰写过的作品或成果。对本论文的研究作出重要贡献的个人和集体，均已在文中以明确的方式标明。本毕业论文的知识产权归属于培养单位。本人完全意识到本声明的法律结果由本人承担。

本人签名：

日期：

Statement of Academic Integrity

I hereby acknowledge that the thesis submitted is a product of my own independent research under the supervision of my supervisor, and that all the data, statistics, pictures and materials are reliable and trust- worthy, and that all the previous research and sources are appropriately marked in the thesis, and that the intellectual property of the thesis belongs to the school. I am fully aware of the legal effect of this statement.

Student Signature:

Date:

层叠成像中的相位恢复问题

摘要

本文主要讨论偏相干层叠成像中的相位恢复问题。根据被偏向干效应污染的无相位的衍射图序列，恢复出真实图像和用于成像的探针。为了刻画偏向干效应，选用了多种物理模型中的一个，并详细讨论了它与一般化的多模态模型间的关系。将直观的交替投影方法改进为 ADMM 算法，并拓展到多个模态的情形。我们进行了三个仿真数值实验验证了算法的有效性。第一，模态逼近实验。随着模态数目增加，逼近密度矩阵的精度提高，图像的恢复质量提升。算法恢复出来的模态与根据模型产生的标准答案高度相似。第二，尝试在 ADMM 中加入正交化约束，避免搜索过程中不同模态的信息重叠，提升算法的效率。第三，有噪声的情形。

关键词：相位恢复 偏向干层叠成像 ADMM

Partially coherent ptychography

Abstract

Key words: Variable Selection Machine Learning Prediction

Contents

1	引言	1
1.1	选题背景与意义	1
1.2	国内外研究现状和相关工作	1
1.3	本文论文结构与章节安排	2
2	模型	3
2.1	纯相干模型	3
2.2	一些具体的偏相干模型	3
2.2.1	模型一 ^[1]	3
2.2.2	模型二 ^[9]	4
2.3	一般的偏向干模型	4
2.3.1	一般化的分解模型	4
2.3.2	模型之间的关系	5
3	基于 ADMM 的数值算法	7
3.1	子问题 w 和 u	9
3.2	子问题 z	9
3.3	子问题 D 和 α	10
4	数值实验	11
4.1	实验设置	11
4.1.1	参数	11
4.1.2	度量指标	12
4.1.3	对模态的操作	13
4.2	实验：多模态逼近偏向干效应	13
4.3	加入正交约束条件	17
4.4	有噪声的情形	17
5	附录	19
5.1	ADMM 中的子问题	19
5.1.1	ω	19
5.1.2	z	19
5.1.3	D	20

List of Figures

1	14
2	R and snr.	14
3	模态分解。第一行代表“标准模态分解”。最后两行代表 12 种模态的具体样式。这里的模态被表示在在时域中，除了最后一行在频域中。	15
4	标准密度矩阵的奇异值分布。左边子图中的纵轴代表 i^{th} 最大奇异值与第一个 s_i/s_1 的比值，右边的纵轴代表 $S_{cum}(i)$ 。奇异值呈指数下降，矩阵近似低秩。	16
5	16
6	纵轴和横轴在 R 因子的第一个子图中以对数刻度设置。蓝线代表 $\beta_2/\beta = 1000$ ，在这种情况下效果最好。绿线表示没有正交化的结果。“ort 1”表示每 20 次迭代执行一次正交化。	17
8	R and snr. The red line represents the result with compression.	18
7	Reconstructed images in the noisy case	18

List of Tables

1 引言

1.1 选题背景与意义

层叠成像是科学领域中一种流行的成像技术，如凝聚态物理、细胞生物学、材料科学和电子学等。在相干光层叠成像实验中，局部的相干 X 射线探头扫描样本，而探测器在远场收集一系列无相位的观测强度值。我们的目标是从强度测量序列中获得样本的高分辨率重建。

相干层叠成像实验通常依靠光圈来定义相干照明。世界各地的研究机构都在投入大量资源来生产更亮的 X 射线源以克服这一限制。同时，大多数产生的 X 射线光子目前都被二级孔径丢弃。即使有足够强度的相干光，曝光期间所需的稳定性通常也是另一个限制因素。总之，相干光源需要严格的实验条件，可能会造成浪费。使用偏相干分析可以减少光强和稳定性限制。

1.2 国内外研究现状和相关工作

为了表示偏相干效应，研究者们提出了不同的前向模型。物理学家在^[3]中提出了一个通用模型，它是一种基于 quantum state tomography 描的盲层叠成像模型，它假设探针处于具有 r 个模态的混合状态。诸如交替投影 (AP) 之类的算法可以从相干情况扩展到偏相干情况以找到 r 个主要模态。在另一种观点中，我们正在重构一个近似的 $rank - r$ 密度矩阵。尽管该模型在各种情况下成功地重建了图像，例如具有平移模糊的“飞行扫描”数据，但多种模式的物理解释尚不清楚，并且与相干函数的关系是间接的。因此，研究者们对不同的实验设置^[9]提出了一些特定的模型。

在^[1]中，作者将偏相干效应描述为具有振动核 κ 的主要模态 ω 上的模糊。因为这个前向模型很难计算，他们使用了探针梯度分解 (GDP)，一种新的前向模型，来近似它。然后他们提出了 GDP-ADMM，这是一种迭代求解器，可以联合优化图像、探针和模糊核函数的方差。然而，当模糊核方差大小增加时，逼近精度下降，结果看起来很模糊。他们假设内核是高斯的，只优化方差参数，这可能不适合真实世界的的数据。在另一个更简单的模型中，偏相干效应的特征是直接在相干情况下的测量值上添加模糊。它可以被解释为在检测器处模糊或合并多个像素。

在本文中，我们想用数学语言来描述偏相干，并设计一种有效的算法来解决这个问题。我们将主要关注^[1]中的振动模型，结合不同模型的优点，得到一个泛化能力和解释能力都很好的模型。然后，我们将利用模型的特殊结构设计一种算

法，并进行数值实验以证明其效率。

1.3 本文论文结构与章节安排

本文共分为五节，每章节的内容如下：

第一节：引言。

第二节：模型。详细介绍偏相干效应的不同模型，并阐述他们的联系。

第三节：算法。

第四节：实验。

2 模型

2.1 纯相干模型

$$f_j = |\mathcal{F}(\mathcal{S}_j u \circ \omega)|^2 \quad (1)$$

在离散的情况下, $u \in \mathbb{C}^n$ 是一个 2D 图像, 有着 $\sqrt{n} \times \sqrt{n}$ 个像素, $\omega \in \mathbb{C}^{\bar{m}}$ 是一个 2D 的局部探针, 有着 $\sqrt{\bar{m}} \times \sqrt{\bar{m}}$ 个像素.

$f_j \in \mathbb{R}_+^{\bar{m}} (\forall 0 \leq j \leq N-1)$ 是一叠没有相位的观测值. 这里 $|\cdot|$ 代表一个向量逐个元素取绝对值, \circ 代表逐个元素的乘法, \mathcal{F} 代表标准化后的离散二维傅里叶变换. 每个 $\mathcal{S}_j \in \mathbb{R}^{\bar{m} \times n}$ 是一个 0-1 矩阵, 将大小为 size \bar{m} 的区域 j 从图像 u 中割下来.

在实际中, 由于无法完全了解该探针, 我们需要解决盲层叠成像的相位恢复 (BP-PR) 问题:

要找到 $\omega \in \mathbb{C}^{\bar{m}}$ and $u \in \mathbb{C}^n$ s.t. $|\mathcal{A}(\omega, u)| = \mathbf{a}$,

在这里双线性算子 $\mathcal{A} : \mathbb{C}^{\bar{m}} \times \mathbb{C}^n \rightarrow \mathbb{C}^m$ 和 $\mathcal{A}_j : \mathbb{C}^{\bar{m}} \times \mathbb{C}^n \rightarrow \mathbb{C}^m \forall 0 \leq j \leq N-1$ 的意义如下:

$$\begin{aligned} \mathcal{A}(\omega, u) &:= (\mathcal{A}_0^T(\omega, u), \mathcal{A}_1^T(\omega, u), \dots, \mathcal{A}_{N-1}^T(\omega, u))^T, \mathcal{A}_j(\omega, u) := \mathcal{F}(\omega \circ \mathcal{S}_j u) \\ \text{和 } \mathbf{a} &:= (\mathbf{a}_0^T, \mathbf{a}_1^T, \dots, \mathbf{a}_{N-1}^T)^T \in \mathbb{R}_+^m. \end{aligned}$$

2.2 一些具体的偏相干模型

2.2.1 模型一^[1]

在连续情形:

$$f_{pc,j}(q) = \int |\mathcal{F}_{x \rightarrow q}(\mathcal{S}_j u(x) \omega(x-y))|^2 \kappa(y) dy \quad (2)$$

这里 f_{pc} 偏向于情形下的观测强度, $\mathcal{F}_{x \rightarrow q}$ 是标准傅里叶变换. κ 是一个在 0 处突起的函数, 如高斯函数. 设置 κ 为狄拉克函数将它化简为纯相干模型 (1).

在离散情形下:

$$f_{pc,j} = \sum_i \kappa_i |\mathcal{F}(\mathcal{S}_j u \circ (\mathcal{T}_i \omega))|^2 \quad (3)$$

符号的含义解释如下: 平移算子 \mathcal{T}_i , 离散高斯函数的权重 $\{\kappa_i\}$, 探针设为周期性边界条件.

广泛地说, 解决 (3) 是一个 non-linear ill-posed problem, 我们不知道的有模糊核 κ , 探针 ω , 和目标图像 u .

2.2.2 模型二^[9]

这里介绍一个更简单的模型:

$$f_{pc} = f * \kappa \quad (4)$$

这里 f_{pc} 是观测到的偏向干强度, f 是纯相干情形下观测到的强度 (1), $*$ 是卷积算子, κ 是未知的模糊核函数

我们注意到 (3) 与 (4) 不同, 因为 (3) 说明了图像相对于探头的模糊效果, 而 (4) 可以解释为探测器模糊或合并多个像素。

2.3 一般的偏向干模型

这部分介绍了物理学家提出的偏相干模型。^[3] 它是基于 quantum state tomography¹。假设探针 w 处于混合状态以表示偏向干的效果。

2.3.1 一般化的分解模型

Find u, r orthogonal w_k s.t.

$$f_{pc,j} = \sum_{k=1}^r |\mathcal{F}(\mathcal{S}_j u \circ (\omega_k))|^2 \quad (0 \leq j \leq N-1) \quad (5)$$

将 $O_j \in C^{\bar{m} \times \bar{m}}$ 表示为 (对角线) 矩阵, 以表示对 w 的线性变换, s.t. $\mathcal{S}_j u \circ \omega = O_j w$ 。将 $f_q^* \in C^{1 \times \bar{m}}$ 表示为由傅里叶变换 \mathcal{F} 构造的行向量, 以表示在频率元素上的投影。构造测量矩阵 $\mathcal{I}_{j\mathbf{q}} = O_j^* f_q f_q^* O_j$ 和密度矩阵 ρ , 我们得到另一种形式 (实际上是 quantum state tomography 中的自然形式) 该模型:

Find u, ρ , s.t.

$$f_{pc,j}(q) = \text{Tr}(\mathcal{I}_{j\mathbf{q}} \rho) \quad (0 \leq j \leq N-1) \quad (6)$$

ρ is positive semi-definite, with $\text{rank} \leq r$

接下来, 我们将解释这种形式的推导。

简单的计算过程:

$$f_{pc,j}(q) = |f_q^* O_j w|^2 = (f_q^* O_j w)^* (f_q^* O_j w) = w^* (O_j^* f_q f_q^* O_j) w$$

¹https://homepage.univie.ac.at/reinhold.bertlmann/pdfs/T2_Skript_Ch_9corr.pdf 定理 9.1 的盲 ptychography 模型。这里包含了许多量子力学中的符号。

$$\begin{aligned}
&= \text{Tr}[w^*(O_j^* f_q f_q^* O_j)w] = \text{Tr}[(O_j^* f_q f_q^* O_j)(ww^*)] \\
&= \text{Tr}(\mathcal{I}_{j\mathbf{q}}\rho)
\end{aligned}$$

这有点像相位提升的过程。

当 w 处于单一状态（希尔伯特空间中的一个向量）时， $\rho = w^*w$ 是一个秩一矩阵。在偏相干的情况下，我们使用混合状态来建模 w 。例如，在状态 ψ_1 中的概率为 0.5，在 ψ_2 中的概率为 0.5（ ψ_1 和 ψ_2 在这里不一定是正交的）。现在 w 不能再由向量表示了（ps. $w \neq p_1\psi_1 + p_2\psi_2$ ，后者仍然是一个确定的纯状态向量）。相反，混合状态由将密度矩阵泛化为具有更高秩的矩阵表示：

$$\rho = \sum_k p_k \psi_k \psi_k^*$$

容易发现 ρ 是一个半正定矩阵，我们可以利用谱定理分解 ρ ， r (rank of ρ) 正交状态 w_k ：

$$\rho = \sum_{k=1}^r w_k w_k^* \quad (7)$$

$$\begin{aligned}
f_{pc,j}(q) &= \text{Tr} \mathcal{I}_{j\mathbf{q}}\rho = \text{Tr}[\mathcal{I}_{j\mathbf{q}} \sum_{k=1}^r w_k w_k^*] \\
&= \sum_{k=1}^r w_k^* \mathcal{I}_{j\mathbf{q}} w_k = \sum_{k=1}^r |f_q^* O_j w_k|^2
\end{aligned}$$

而这正是 (5) $f_{pc,j} = \sum_{k=1}^r |\mathcal{F}(\mathcal{S}_j u \circ (\omega_k))|^2$ 。（ $f_{pc,j}(q)$ 是在频率 q 处的单一值，而 $f_{pc,j}$ 是整个衍射图像）

我们可以把这个写成二次型的形式：

$$\begin{aligned}
f_{pc,j}(q) &= \text{Tr} \mathcal{I}_{j\mathbf{q}}\rho = \text{Tr}[(O_j^* f_q f_q^* O_j)\rho] = \text{Tr}[(O_j^* f_q)^* \rho (O_j^* f_q)] = (O_j^* f_q)^* \rho (O_j^* f_q) \\
&= g_q^* \rho g_q = \sum_{x_1} \sum_{x_2} \overline{g_q(x_1)} \rho(x_1, x_2) g_q(x_2)
\end{aligned} \quad (8)$$

where $g_q = O_j^* f_q = \overline{S_j u} \circ f_q$, $\overline{g_q} = S_j u \circ \overline{f_q}$

这是^[9]中提到模型的离散版本。

2.3.2 模型之间的关系

在本节中，我们将解释通用模型如何与特定模型 (3) 和 (4) 联系。

首先我们考虑 (3)。我们把 κ_i 放在里面：

$$f_{pc,j} = \sum_i |\mathcal{F}(\mathcal{S}_j u \circ (\sqrt{\kappa_i} \mathcal{T}_i \omega))|^2 = \sum_i |\mathcal{F}(\mathcal{S}_j u \circ (\hat{\omega}_i))|^2 \quad (9)$$

多种模态 \hat{w}_i 由移位 w 产生。然后我们可以构造密度矩阵并使用 SVD 得到一个低秩近似。

$$\rho = \sum_i \hat{w}_i \hat{w}_i^* \approx \sum_{k=1}^r w_k w_k^*$$

至于 (4), 我们介绍 coherence function 的定义：

$$\gamma(x_1, x_2) = \frac{\rho(x_1, x_2)}{w(x_1)w(x_2)}$$

也就是：

$$\gamma = \rho ./ (w w^*), \rho = \gamma \circ (w w^*) \quad (10)$$

这里 $./$ 意味着逐个元素的除法。

当我假设 coherence function $\gamma(\mathbf{x}_1, \mathbf{x}_2)$ 只与两个点之间的距离有关 $\mathbf{x}_1, \mathbf{x}_2$, i.e. $\gamma(\mathbf{x}_1, \mathbf{x}_2) = \gamma(0, \mathbf{x}_2 - \mathbf{x}_1)$, 我们可以把远场强度写成一个卷积的形式^[9]

$f_{pc} = \kappa * f$. 如果我们知道 point spread function $\kappa(q)$, 那我们可以得到它的傅里叶逆变换 $\gamma(0, x) = (\mathcal{F}^{-1} \kappa)(x)$. 在这个假设上, 我们得到 $\gamma(x_1, x_2)$. 如果我们也知道探针 w , 那我们可以得到 ρ , SVD 帮助我们在模型 (5) 中找到主要模态 w_k 。

通过上面的不同模型间的联系, 我们可以得到“标准模式分解”作为参考。

3 基于 ADMM 的数值算法

常用的交替投影算法 (AP) 可以被重写成 ADMM 形式, 它更快而且更稳定. 我们推广^[8] 中的 ADMM 算法到多模态的情形. 为了引导算法找到的多个模态信息不重叠, 提高搜索效率, 我们还引入了模态间的正交约束。

现在 $w \in \mathbb{C}^{(px \times py) \times r}$ 是 r 个模态 r . $u \in \mathbb{C}^{Nx \times Ny}$ 是图像. $f \in \mathbb{C}^{(px \times py) \times N}$ 是真实观察到的衍射图像. 记 $Y = \sqrt{f}$ 为对应模长.

一个辅助变量 $z = \mathcal{A}(\omega, u) \in \mathbb{C}^{(px \times py) \times N \times r}$ 被引入. \mathcal{A} 是一个从图像 u 和 r 个不同模态 $w_k := w(:, :, k) \in \mathbb{C}^{px \times py}$ 产生衍射图像序列的算子, 每个模态产生 N 帧. 对于多维向量, 符号: 表示自由维度, 我们可以固定一些索引来从原始向量中提取特定维度。

根据一般模型3, 问题叙述为:

$$\text{Find } \omega, u \text{ s.t.}$$

$$\bar{\mathcal{A}}(\omega, u) = Y$$

这里 $\mathcal{A} : \mathbb{C}^{(px \times py) \times r} \times \mathbb{C}^{Nx \times Ny} \rightarrow \mathbb{C}^{(px \times py) \times N \times r}$, $\mathcal{A}_j : \mathbb{C}^{px \times py} \times \mathbb{C}^{Nx \times Ny} \rightarrow \mathbb{C}^{px \times py}$, $\bar{\mathcal{A}}_j : \mathbb{C}^{(px \times py) \times r} \times \mathbb{C}^{Nx \times Ny} \rightarrow \mathbb{R}_+^{(px \times py)}$, 而且 $\bar{\mathcal{A}} : \mathbb{C}^{(px \times py) \times r} \times \mathbb{C}^{Nx \times Ny} \rightarrow \mathbb{R}_+^{(px \times py) \times r} (\forall 0 \leq j \leq N-1)$ 被表示为:

$$z(:, :, j, k) = \mathcal{A}_j(\omega_k, u) := \mathcal{F}(\omega_k \circ \mathcal{S}_j u) \in \mathbb{C}^{px \times py},$$

$$z(:, :, :, k) = (\mathcal{A}_0^T(\omega_k, u), \mathcal{A}_1^T(\omega_k, u), \dots, \mathcal{A}_{N-1}^T(\omega_k, u))^T \in \mathbb{C}^{(px \times py) \times N},$$

$$z(:, :, j, :) = (\mathcal{A}_j^T(\omega_1, u), \mathcal{A}_j^T(\omega_2, u), \dots, \mathcal{A}_j^T(\omega_r, u))^T \in \mathbb{C}^{(px \times py) \times r}.$$

,

$$\bar{\mathcal{A}}_j(\omega, u) := \sum_{k=1}^r |\mathcal{A}_j(\omega_k, u)|^2 \in \mathbb{R}_+^{px \times py},$$

$$\bar{\mathcal{A}}(\omega, u) := (\bar{\mathcal{A}}_0^T(\omega, u), \bar{\mathcal{A}}_1^T(\omega, u), \dots, \bar{\mathcal{A}}_{N-1}^T(\omega, u))^T \in \mathbb{R}_+^{(px \times py) \times N},$$

$$\text{和 } Y = (\mathbf{a}_0^T, \mathbf{a}_1^T, \dots, \mathbf{a}_{N-1}^T)^T \in \mathbb{R}_+^{(px \times py) \times N}.$$

那么 $\mathcal{G}(z) = \|\sqrt{\sum_{k=1}^r |z(:, :, :, k)|^2} - Y\|^2$ 测量模型计算的值与真实值之间的差异。

\mathcal{X}_1 和 \mathcal{X}_2 表示 w 和 u 的先验范围. $l = px \times py$, \mathcal{X}_3 是正交指示函数 $D\alpha \in \mathbb{C}^{l \times r}$ ($D \in \mathbb{C}^{l \times r}$ 标准正交 s.t. $D^* D = I$), $\alpha \in \mathbb{R}^{r \times r}$ 表示模长. Ω 是一个形状调整算子, $\Omega(D\alpha) := \text{reshape}(D\alpha, [px, py, r]) \in \mathbb{C}^{(px \times py) \times r}$. 有时候我们将 $\Omega(D^k \alpha^k)$ 简写为 Ω^k , $\Omega(D\alpha)$ 简写为 Ω .

于是我们得到:

$$\begin{aligned} \min_{\omega, u, z} \mathcal{G}(z) + \mathbb{I}_{\mathcal{X}_1}(\omega) + \mathbb{I}_{\mathcal{X}_2}(u) + \mathbb{I}_{\mathcal{X}_3}(D\alpha) \\ \text{s.t. } z - \mathcal{A}(\omega, u) = 0, \quad \Omega(D\alpha) - w = 0. \end{aligned} \quad (11)$$

相应的增广拉格朗日乘子为:

$$\begin{aligned} \Upsilon_\beta(\omega, u, z, \Lambda) := & \mathcal{G}(z) + \mathbb{I}_{\mathcal{X}_1}(\omega) + \mathbb{I}_{\mathcal{X}_2}(u) + \Re(\langle z - \mathcal{A}(\omega, u), \Lambda \rangle) + \frac{\beta}{2} \|z - \mathcal{A}(\omega, u)\|^2 \\ & + \Re(\langle \Omega(D\alpha) - w, \Lambda_2 \rangle) + \frac{\beta_2}{2} \|\Omega(D\alpha) - w\|^2 \end{aligned}$$

这里 $\Lambda, \Lambda_2 \in \mathbb{C}^{(px \times py) \times N \times r}$ 是乘子. Let $\Lambda = \Lambda/\beta, \Lambda_2 = \Lambda_2/\beta_2$, 我们将 \Re 部分和增广部分组合起来得到:

$$\begin{aligned} \Upsilon_\beta(\omega, u, z, \Lambda) := & \mathcal{G}(z) + \mathbb{I}_{\mathcal{X}_1}(\omega) + \mathbb{I}_{\mathcal{X}_2}(u) + \mathbb{I}_{\mathcal{X}_3}(D\alpha) \\ & + \frac{\beta}{2} \|z - \mathcal{A}(\omega, u) + \Lambda\|^2 - \frac{\beta}{2} \|\Lambda\|^2 + \frac{\beta_2}{2} \|\Omega(D\alpha) - w + \Lambda_2\|^2 - \frac{\beta_2}{2} \|\Lambda_2\|^2 \end{aligned} \quad (12)$$

在 ADMM 中, 寻求以下问题的鞍点:

$$\max_{\Lambda, \Lambda_2} \min_{\omega, u, z, D, \alpha} \Upsilon_\beta(\omega, u, z, \Lambda, \Lambda_2, D, \alpha)$$

解决上述鞍点问题的一个自然方案是将它们分裂, 得到包括四步迭代的 ADMM (只有 ω 或 u 的子问题具有近端项), 如下所示:

$$\text{Step 1: } \omega^{k+1} = \arg \min_{\omega} \Upsilon_\beta(\omega, u^k, z^k, \Lambda^k) + \frac{\beta_2}{2} \|\omega - (\Omega(D^k \alpha^k) + \Lambda_2)\|^2 + \frac{\alpha_1}{2} \|\omega - \omega^k\|_{M_1^k}^2,$$

$$\text{Step 2: } u^{k+1} = \arg \min_u \Upsilon_\beta(\omega^{k+1}, u, z^k, \Lambda^k) + \frac{\alpha_2}{2} \|u - u^k\|_{M_2^k}^2,$$

$$\text{Step 3: } z^{k+1} = \arg \min_z \Upsilon_\beta(\omega^{k+1}, u^{k+1}, z, \Lambda^k),$$

$$\text{Step 4: } D^{k+1} = \arg \min_D \mathbb{I}_{\mathcal{X}_3}(D\alpha) + \frac{\beta_2}{2} \|\Omega(D^k \alpha^k) - \omega^{k+1}\|^2$$

$$\text{Step 5: } \alpha^{k+1} = \arg \min_{\alpha} \frac{\beta_2}{2} \|\Omega(D^{k+1} \alpha^k) - \omega^{k+1}\|^2$$

$$\text{Step 6: } \Lambda^{k+1} = \Lambda^k + (z^{k+1} - \mathcal{A}(\omega^{k+1}, u^{k+1})) \quad (13)$$

$$\text{Step 7: } \Lambda_2^{k+1} = \Lambda_2^k + (\Omega(D^{k+1} \alpha^{k+1}) - \omega^{k+1}) \quad (14)$$

为简单起见, 我们在下面的分析中忽略了 Step1 和 Step2 中的稳定二次项。

3.1 子问题 w 和 u

w.r.t. the probe ω :

$$\begin{aligned}
\omega^{k+1} &= \arg \min_{\omega \in \mathcal{X}_1} \frac{1}{2} \|z^k + \Lambda^k - \mathcal{A}(\omega, u^k)\|^2 + \frac{\beta_2}{2} \|\omega - (\Omega^k + \Lambda_2^k)\|^2 \\
&= \arg \min_{\omega \in \mathcal{X}_1} \frac{1}{2} \|\hat{z}^k - \mathcal{A}(\omega, u^k)\|^2 + \frac{\beta_2}{2} \|\omega - \hat{\Omega}^k\|^2 \\
&= \arg \min_{\omega \in \mathcal{X}_1} \frac{1}{2} \sum_{j,i} \|\mathcal{F}^{-1} \hat{z}(:, :, j, i)^k - \omega(:, :, i) \circ \mathcal{S}_j u^k\|^2 + \frac{\beta_2}{2} \sum_i \|\omega(:, :, i) - \hat{\Omega}^k(:, :, i)\|^2 \\
&\text{with } \hat{z}^k := z^k + \Lambda^k, \hat{\Omega}^k := \Omega^k + \Lambda_2^k
\end{aligned}$$

步骤 1 的近似解为 (详见附录 5.1)

$$\omega^{k+1} = \text{Proj} \left(\frac{\beta \sum_j (\mathcal{S}_j u^k)^* \circ [(\mathcal{F}^{-1} \hat{z}^k) (:, :, j, :)] + \beta_2 \hat{\Omega}^k}{\beta \sum_j |\mathcal{S}_j u^k|^2 + \beta_2}; \mathcal{X}_1 \right) \quad (15)$$

到 \mathcal{X}_1 的投影算子定义为 $\text{Proj}(\omega; \mathcal{X}_1) := \mathcal{F}^{-1}(\mathcal{F}(\omega) \circ C_w)$, 这里 $\mathcal{X}_1 = \{\omega : \mathcal{F}(\omega) \text{ supports on the index function } C_w\}$. \mathcal{F}^{-1} 作用在 \hat{z} 的前两个维度上 (i.e. $\hat{z}_{j,i} := \hat{z}(:, :, j, i)$) and ω (i.e. $\omega_i := \omega(:, :, i)$).

我们有:

$$u^{k+1} = \text{Proj} \left(\frac{\sum_{j,i} \mathcal{S}_j^T \left((\omega_i^{k+1})^* \circ \mathcal{F}^{-1} \hat{z}_{j,i}^k \right)}{\sum_{j,i} \left(\mathcal{S}_j^T |\omega_i^{k+1}|^2 \right)}; \mathcal{X}_2 \right). \quad (16)$$

这里 \mathcal{S}_j^T 是将参数映射到图像 u 中的目标位置 j 的算子。

3.2 子问题 z

$$\begin{aligned}
z^{k+1} &= \arg \min_z \mathcal{G}(z) + \frac{\beta}{2} \|z - \mathcal{A}(\omega^{k+1}, u^{k+1}) + \Lambda^k\|^2 \\
&= \arg \min_z \frac{1}{2} \left\| \sqrt{\sum_{i=1}^r |z(:, :, :, i)|^2 - Y} \right\|^2 + \frac{\beta}{2} \|z - z^+\|^2 \\
&= \arg \min_z \sum_{x,y,j} \left[\frac{1}{2} \left(\sqrt{\sum_{i=1}^r |z(x, y, j, i)|^2 - Y(x, y, j)} \right)^2 + \frac{\beta}{2} \|z(x, y, j, :) - z^+(x, y, j, :)\|^2 \right]
\end{aligned}$$

这里 $z^+ = \mathcal{A}(\omega^{k+1}, u^{k+1}) - \Lambda^k$

Step 3 的闭形式解为（详见附录 5.1）:

$$z_i^{k+1} = \frac{z_i^+ \frac{Y}{M^k} + \beta z_i^+}{1 + \beta}, 1 \leq i \leq r \quad (17)$$

where $z_i := z(:, :, :, i)$ and $M^k = \sqrt{\sum_i |z_i^+|^2} \in \mathbb{C}^{px \times py \times N}$

3.3 子问题 D 和 α

$$\begin{aligned} D^{k+1} &= \arg \min_D \|\Omega - w^{k+1} + \Lambda_2^k\|^2 \\ &= \arg \min_D \|D\alpha^k - \hat{w}^{k+1}\|^2 \end{aligned}$$

这里 $\hat{w}^{k+1} = \text{reshape}(\omega^{k+1} - \Lambda_2^k, [l, r]), D^*D = I$

D^{k+1} 的闭形式是 (细节在附录中 5.1):

$$D^{k+1} = UV^* \quad (18)$$

α 的更新更加简单:

$$\alpha^{k+1} = \arg \min_{\alpha} \|D^{k+1}\alpha - \hat{w}^{k+1}\|^2 = \arg \min_{\alpha} \sum_i \|\alpha_i D^{k+1}(:, i) - \hat{w}^{k+1}(:, i)\|^2$$

注意到每个 $\alpha_i \in \mathbb{R}$ 可以被独立地解决, 一阶优化条件给出:

$$\alpha_i^{k+1} = \sum_{i_0} \Re[\overline{D^{k+1}(i_0, i)} \hat{w}^{k+1}(i_0, i)] (1 \leq i \leq r) \quad (19)$$

Algorithm 1: ADMM for general mixed-state model(5)

Initialization: Set the number of states r , $\omega^0, u^0, z^0 = \mathcal{A}(\omega^0, u^0), \Lambda^0, \Lambda_2^0 = 0$;

D^0 and α^0 from SVD on ω^0

maximum iteration number Iter_{Max} , and parameter β, β_2

Output: $u^* := u^{\text{Iter}_{\text{Max}}}$ and $\omega^* := \omega^{\text{Iter}_{\text{Max}}}$

1 **for** $ii = 0$ **to** $\text{Iter}_{\text{Max}} - 1$ **do**

2 Compute ω^{k+1} by (15) with $\hat{z}^k := z^k + \Lambda^k$;

3 Compute u^{k+1} (16). with \hat{z}^k the same as above;

4 Compute $z_i^{k+1}, 1 \leq i \leq r$ by (20). with $z^+ = \mathcal{A}(\omega^{k+1}, u^{k+1}) - \Lambda^k$;

5 Compute D^{k+1} (21). ;

6 Compute $\alpha_i, 1 \leq i \leq r$ (19). ;

7 Update the multiplier as Step 6 and Step 7 of (13) and (14);

8 **end**

4 数值实验

代码在 MATLAB 中实现。首先，我们介绍实验中的设置，然后我们对 2.2 中的特定模型生成的仿真数据进行实验。在每个实验中，我们比较不同设置中的重建图像和模态。我们还生成了 2.3.2 中的“标准模态分解”，并将我们的结果与它们进行比较。

4.1 实验设置

4.1.1 参数

Parameters	Illustration	Values
N_x, N_y	size of image u	128,128
p_x, p_y	size of phobe w	64,64
$Dist$	scan distance between neighborhood frames	4,8,16
N	number of frames in diffusion image stacks	
r	number of states(modes)	1(coherent) to 15
gridFlag	types of scan methods	1(rectangular lattice), 2(hexagonal),3(randomly disturb on 2)
blurFlag	types of partially coherent effect	1(4),2(3)

为了处理不平凡模糊性，非周期性的扫描可以去除扫描几何的周期性，例如，将少量随机偏移添加到扫描网格集中。 $(gridFlag = 3)$ 。或者我们可以添加关于模态的先验知识作为附加约束，例如将模态（频域）限制在一个圆圈内。

$Dist$ 是成功重建的重要参数。一般而言， $Dist$ 越小，数据中的重叠区域和冗余越多，我们可以得到质量更高的重建图像。在这里我们发现 $Dist = 8$ 就足够了，而 $Dist = 16$ 总是失败。

4.1.2 度量指标

为了评估算法的性能，我们引入了 3 个指标。

1. 相对误差 err 和信噪比 snr

$$err^k = \frac{\|cu^k - u_{true}\|_F}{\|cu^k\|_F}, c = \frac{sum(u_{true} \circ \overline{u^k})}{\|u^k\|_F^2}$$

$$snr^k = -20 \log_{10}(err^k)$$

$\|\cdot\|_F$ 是 Frobenius 范数。 err 测量重建图像和真实图像之间的差异。 c 是估计的比例因子， sum 表示目标矩阵中所有元素的总和。

2. R-factor R

Let $zz = \mathcal{A}_j(\omega^k, u^k)$

$$R^k := \frac{\left\| \sqrt{\sum_{i=1}^r |zz(:, :, i)|^2} - Y \right\|_1}{\|Y\|_1}$$

R 测量重建衍射序列和真实虚了 Y 之间的差异。我们并不总是知道真实图像 u_{true} ，衍射序列 Y 是我们算法的唯一输入数据，因此 R-factor 可以用来验证收敛。

3. 模态逼近误差 err_M

$$err_M^k = \frac{\|c\rho^k - \rho_{true}\|_F}{\|\rho_{true}\|_F}, c = \frac{sum(\rho_{true} \circ \overline{\rho^k})}{\|\rho^k\|_F^2}$$

err_M 测量来自模态的重建密度矩阵 ρ^k 与来自理论模型的标准密度矩阵 ρ_{true} 之间的差异。

4.1.3 对模态的操作

1. 初始化

在以下实验中，我们设置 $u^0 = \mathbf{1}_{N_x \times N_y}$ 和初始探针 $m = \frac{1}{N} \mathcal{F}^{-1} \left(\sum_j Y(:, :, j) \right)$ 。我们通过随机干扰一个初始模态 m 来生成其他初始模态。 r 个初始模态是通过将初始模态乘以不同的随机复数值数组来创建的（模长部分在 $[0, 1]$ ，相位部分在 $[0, 2\pi]$ 的范围内。）然后我们得到 w^0 。

2. 正交化

在我们的算法中计算的模式 w_k 并不总是正交的。然而，我们可以通过生成密度矩阵 ρ 来轻松正交化它们，并像在 (7) 中一样对 ρ 执行谱分解。模式的正交表示一般是唯一的（特别是当 ρ 的特征值都不同时，这总是发生在现实世界的的数据中）。

注意到，模态的数量总是较小，即 $r \ll l := p_x \times p_y$ ，我们直接对 $l \times r$ 模态矩阵执行 SVD，而不是 $l \times l$ 密度矩阵 ρ 。我们还可以选择前 $r' \leq r$ 个模态进行近似。

Algorithm 2: SVD-based orthogonalization for phobes(Matlab)

Input: $w \in \mathbb{C}^{p_x \times p_y \times r}$, the number of modes needed r'

Output: $w_{ort} \in \mathbb{C}^{p_x \times p_y \times r'}$

- 1 phobe matrix $ss = \text{reshape}(w, [l \ r])$;
 - 2 $[U, S, V] = \text{svd}(ss, 'econ')$;
 - 3 $q = U(:, 1 : r') * S(1 : r', 1 : r')$;
 - 4 $w_{ort} = \text{reshape}(q, [p_x \ p_y \ r'])$;
-

为了获得更清晰的表达，在我们显示最终模态之前总是执行正交化操作。我们还想弄清楚是否可以添加正交化来改进我们的算法1。

3. 压缩

在嘈杂的情况下，我们考虑提取较少的主要模式以避免噪声失真。

4.2 实验：多模态逼近偏向干效应


$Dist = 8$, $gridFlag = 1$, $blurFlag = 2$ 和 κ 是一个高斯核， $\sigma = (15, 15)$ 。ADMM 的算法参数选择 $\beta = 0.05$ ，这里不考虑正交化约束，所以 $\beta_2 = 0$ 。

Algorithm 3: SVD-based compression for phobes(Matlab)

Input: $w \in \mathbb{C}^{px \times py \times r}$, the number of main modes kept r'

Output: $w_{com} \in \mathbb{C}^{px \times py \times r}$

- 1 phobe matrix $ss = \text{reshape}(w, [l \ r])$;
- 2 $[U, S, V] = \text{svd}(ss, 'econ')$;
- 3 $a = U(:, 1 : r') * S(1 : r', 1 : r') * V(:, 1 : r')$:



(a) Amplitude



(b) Phase




Figure 2: R and snr.

我们首先比较使用不同数量模态的重建图像的 snr 和 R 。当模态数量增加时，

$R - factor$ 减少, snr 增加。这表明重建图像的质量提高了。

使用 ADMM 算法的 3、6、9、12 个模态逼近算法时, R 在 500 次迭代后稳定在 0.15、0.042、0.0099、0.0028, 而 AP 的 R 在 2000 次迭代后不收敛。




Figure 3: 模态分解。第一行代表“标准模态分解”。最后两行代表 12 种模态的具体样式。这里的模态被表示在在时域中, 除了最后一行在频域中。

“模态标准分解”是通过对模型生成的标准密度矩阵执行 SVD 并提取前 12 个模态获得的。如图 3 所示, 我们的算法通常可以捕获主要模态并获得密度矩阵的最佳近似。

此外, 将 r 个模态的 err_M 表示为 err_M^r 。最优 $err_M^{r,*}$ 可以从低秩逼近理论中计算出来, 我们将我们的 err_M^r 与它进行比较。将标准密度矩阵 ρ_{true} 的奇异值表示为

$$err_M^{r,*} = \min_{\rho, \text{rank}(\rho)=r} \frac{\|\rho_{true} - \rho\|_F}{\|\rho_{true}\|_F} = \sqrt{\frac{\sum_{i=r+1}^d s_i^2}{\sum_i s_i^2}} = \sqrt{1 - s_{cum}(r)}$$

,

$$\text{where } s_{cum}(r) = \frac{\sum_{i=1}^r s_i^2}{\sum_i s_i^2}$$

如图 5 所示, err_M^* 达到 0.01 左右, err_M 接近 err_M^* , 有 12 种模态, 这表明我们的算法在低秩逼近标准密度矩阵中做得不错。




Figure 4: 标准密度矩阵的奇异值分布。左边子图中的纵轴代表 i^{th} 最大奇异值与第一个 s_i/s_1 的比值，右边的纵轴代表 $S_{cum}(i)$ 。奇异值呈指数下降，矩阵近似低秩。




Figure 5




Figure 6: 纵轴和横轴在 R 因子的第一个子图中以对数刻度设置。蓝线代表 $\beta_2/\beta = 1000$ ，在这种情况下效果最好。绿线表示没有正交化的结果。“ort 1”表示每 20 次迭代执行一次正交化。

4.3 加入正交约束条件

实验设置与上面相同，只是我们更改 $ratio = \beta_2/\beta$ 以在 ADMM 中引入正交化约束。 β_2 越大，正交化约束越严格。作为参考，我们还尝试按照算法 2 每 20 次迭代对模态执行正交化操作。

500 次迭代后重建的图像相似，而使用具有正交化约束的 ADMM 算法的 snr 和 $Rfactor$ 改进更快。并且随着 β_2 的增大，模态之间的相关度 $coherence$ 也会下降得更快。

4.4 有噪声的情形

$Dist = 8$, $gridFlag = 3$, $blurFlag = 2$ 和 κ 是一个高斯核， $\sigma = (15, 15)$, $\beta = 0.05$ 。

通过 MATLAB 命令在衍射图像 Y 上添加泊松噪声：

$$Y = \text{poissrnd}(Y * (\eta))/\eta;$$

这里使用 $\eta = 0.0675$ 。

比较了四种不同的设置：9 个模态带噪声、9 个模态无噪声、6 个模态在压缩操作之后被保留、6 个模态带噪声和 6 个模态无噪声。具体来说，我们按照 3 每 20 次迭代进行压缩，每次保持 6 个模态。

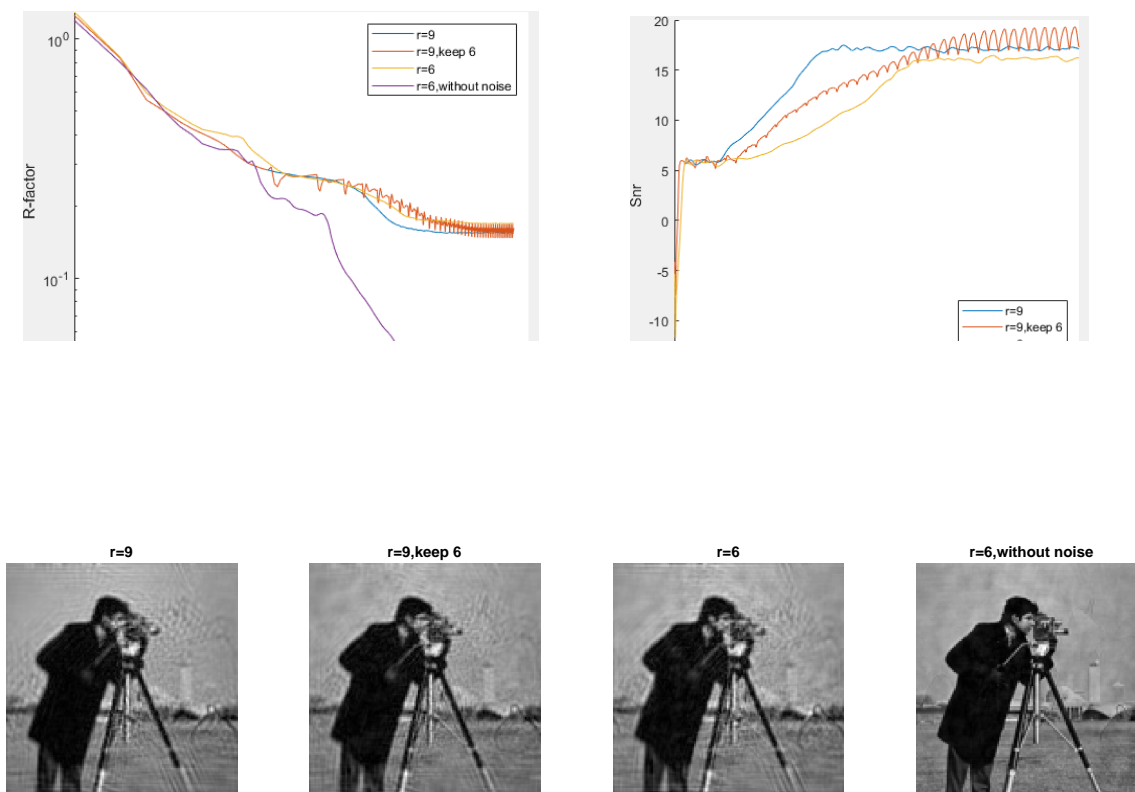


Figure 7: Reconstructed images in the noisy case

结果随着压缩操作周期性地波动，而最终在嘈杂的情况下表现最好。虽然差异并不明显，但我们可以考虑在约束中添加压缩，而不是执行直接截断操作。

5 附录

5.1 ADMM 中的子问题

5.1.1 ω

本质上，在这个子问题中，每个状态 $\omega_i = w(:, :, i)$ 都是独立的。然后我们可以分别优化每个 w_i 。

$$\omega_i^{k+1} = \arg \min_{\omega \in \mathcal{X}_1} \frac{1}{2} \sum_j \left\| \mathcal{F}^{-1} \hat{z}(:, :, j, i)^k - \omega(:, :, i) \circ \mathcal{S}_j u^k \right\|^2$$

本质上，在这个子子问题中， w_i 中的每个元素都是独立的。这样只需要解决以下一维约束二次问题：

$$\omega_i^{k+1}(t) = \arg \min_{|x| \leq C_\omega} \rho_t^k(x).$$

这里 $\rho_t^k(x) := \frac{1}{2} \sum_j \left| (\mathcal{F}^{-1} \hat{z}(:, :, j, i)^k)(t) - x \times (\mathcal{S}_j u^k)(t) \right|^2 \forall x \in \mathbb{C}$

计算 $\rho_t^k(x)$ 的导数。注意这里 ρ 是一个复变量实值函数，我们使用 wirtinger 导数。

$$\begin{aligned} \nabla \rho_t^k(x) &= \frac{d\rho_t^k(x)}{dx^*} \\ &= \sum_j \left(x \times |(\mathcal{S}_j u^k)(t)|^2 - (\mathcal{S}_j u^k)^*(t) (\mathcal{F}^{-1} \hat{z}_{j,i}^k)(t) \right) \\ &= x \times \left(\sum_j |(\mathcal{S}_j u^k)(t)|^2 \right) - \sum_j \left((\mathcal{S}_j u^k)^*(t) (\mathcal{F}^{-1} \hat{z}_{j,i}^k)(t) \right) \end{aligned}$$

一阶最优条件是 $\nabla \rho_t^k(x) = 0$ 。然后 w_i 的闭形式解给出为

$$\omega_i^{k+1} = \text{Proj} \left(\frac{\sum_j (\mathcal{S}_j u^k)^* \circ (\mathcal{F}^{-1} \hat{z}_{j,i}^k)}{\sum_j |\mathcal{S}_j u^k|^2}; C_\omega \right)$$

5.1.2 z

$$\begin{aligned} z^{k+1} &= \arg \min_z \mathcal{G}(z) + \frac{\beta}{2} \|z - \mathcal{A}(\omega^{k+1}, u^{k+1}) + \Lambda^k\|^2 \\ &= \arg \min_z \frac{1}{2} \left\| \sqrt{\sum_{i=1}^r |z(:, :, :, i)|^2 - Y} \right\|^2 + \frac{\beta}{2} \|z - z^+\|^2 \end{aligned}$$

$$= \arg \min_z \sum_{x,y,j} \left[\frac{1}{2} \left(\sqrt{\sum_{i=1}^r |z(x,y,j,i)|^2} - Y(x,y,j) \right)^2 + \frac{\beta}{2} \|z(x,y,j,:) - z^+(x,y,j,:)\|^2 \right]$$

这里 $z^+ = \mathcal{A}(\omega^{k+1}, u^{k+1}) - \Lambda^k$

对于任意固定的 x, y, j 和自由的 i , 问题可以看成:

$$z^*(x, y, j, :) = \arg \min_{z_{x,y,j} \in \mathbb{C}^r} \frac{1}{2} (\|z_{x,y,j}\| - Y_{x,y,j})^2 + \frac{\beta}{2} \|z_{x,y,j} - z_{x,y,j}^+\|^2$$

请注意, 对于固定的 $\|z_{x,y,j}\|$, 表达式中的第一项是固定的。为了优化第二项, 我们应该始终选择与 $z_{x,y,j}^+$ 方向相同的 $z_{x,y,j}$ 。所以我们有 $\|z_{x,y,j} - z_{x,y,j}^+\|^2 = (\|z_{x,y,j}\| - \|z_{x,y,j}^+\|)^2$

$$\frac{z(x, y, j, i)}{\|z_{x,y,j}\|} = \frac{z^+(x, y, j, i)}{\|z_{x,y,j}^+\|}, z(x, y, j, i) = \|z_{x,y,j}\| \frac{z^+(x, y, j, i)}{\|z_{x,y,j}^+\|}$$

要确定 $z_{x,y,j}$, 我们只需要确定 $\|z_{x,y,j}\|$ 。将其表示为 a 。

$$\|z_{x,y,j}\|^* = \arg \min_{a \in \mathbb{R}} \frac{1}{2} (a - Y_{x,y,j})^2 + \frac{\beta}{2} (a - \|z_{x,y,j}^+\|)^2$$

一阶最优性条件很容易给出:

$$a = \frac{Y_{x,y,j} + \beta \|z_{x,y,j}^+\|}{1 + \beta}$$

步骤 3 的闭式形式解为:

$$z_i^{k+1} = \frac{z^+ \frac{Y}{M^k} + \beta z_i^+}{1 + \beta}, 1 \leq i \leq r \quad (20)$$

where $M^k = \sqrt{\sum_i |z^+(\cdot, :, \cdot, i)|^2} \in \mathbb{C}^{px \times py \times N}$

5.1.3 D

$$\begin{aligned} D^{k+1} &= \arg \min_D \|\Omega - w^{k+1} + \Lambda_2^k\|^2 \\ &= \arg \min_D \|D\alpha^k - \hat{w}^{k+1}\|^2 \end{aligned}$$

where $\hat{w}^{k+1} = \text{reshape}(\omega^{k+1} - \Lambda_2^k, [px \times py, r]), D^*D = I$

这是正交 Procrustes 问题中的一个特例.²

$$\begin{aligned}
\|D\alpha^k - \hat{w}^{k+1}\|^2 &= \text{Tr}[(D\alpha^k - \hat{w}^{k+1})^*(D\alpha^k - \hat{w}^{k+1})] \\
&= \|\alpha^k\|_F^2 - \text{Tr}[(\alpha^k)^* D^* \hat{w}^{k+1}] - \text{Tr}[(\hat{w}^{k+1})^* D \alpha^k] + \|\hat{w}^{k+1}\|_F^2 \\
D^{k+1} &= \arg \max_D \text{Tr}[(\alpha^k)^* D^* \hat{w}^{k+1}] + \text{Tr}[(\hat{w}^{k+1})^* D \alpha^k] \\
&= \arg \max_D \Re(\text{Tr}[(\alpha^k)^* D^* \hat{w}^{k+1}]) \\
&\stackrel{\alpha \in \mathbb{R}^{r \times r}}{=} \arg \max_D \Re(\text{Tr}[D^* (\hat{w}^{k+1} \alpha^k)])
\end{aligned}$$

考虑 SVD 分解: $\hat{w}^{k+1} \alpha^k = U S V^*$

$$\begin{aligned}
D^{k+1} &= \arg \max_D \Re(\text{Tr}[D^* U S V^*]) = \arg \max_D \Re(\text{Tr}[(V^* D^* U) S]) \\
&\stackrel{\hat{D} = V^* D^* U}{=} \arg \max_{\hat{D}} \Re(\text{Tr}[\hat{D} S])
\end{aligned}$$

我们得到 $\hat{D} = I_r$ 时是最优的, I_r 为前 r 个对角元为 1, 其余为 0 的对角阵。而且:

$$D^{k+1} = U V^* \quad (21)$$

²https://en.wikipedia.org/wiki/Orthogonal_Procrustes_problem

*Bibliography

- [1] Chang, Huibin, et al. "Partially coherent ptychography by gradient decomposition of the probe." *Acta Crystallographica Section A: Foundations and Advances* 74.3 (2018): 157-169.
- [2] Wolf E. New theory of partial coherence in the space-frequency domain. Part I: spectra and cross spectra of steady-state sources[J]. *JOSA*, 1982, 72(3): 343-351.
- [3] Thibault P, Menzel A. Reconstructing state mixtures from diffraction measurements[J]. *Nature*, 2013, 494(7435): 68-71.
- [4] Tian, Lei, et al. "Multiplexed coded illumination for Fourier Ptychography with an LED array microscope." *Biomedical optics express* 5.7 (2014): 2376-2389.
- [5] Thibault P, Dierolf M, Bunk O, et al. Probe retrieval in ptychographic coherent diffractive imaging[J]. *Ultramicroscopy*, 2009, 109(4): 338-343.
- [6] Griffiths, David J., and Darrell F. Schroeter. *Introduction to quantum mechanics*. Cambridge University Press, 2018.
- [7] Fannjiang A, Strohmer T. The numerics of phase retrieval[J]. *Acta Numerica*, 2020, 29: 125-228.
- [8] Chang, Huibin, Pablo Enfedaque, and Stefano Marchesini. "Blind ptychographic phase retrieval via convergent alternating direction method of multipliers." *SIAM Journal on Imaging Sciences* 12.1 (2019): 153-185.
- [9] Konijnenberg S. An introduction to the theory of ptychographic phase retrieval methods[J]. *Advanced Optical Technologies*, 2017, 6(6): 423-438.
- [10] Attouch H, Bolte J, Redont P, et al. Proximal alternating minimization and projection methods for nonconvex problems: An approach based on the Kurdyka-Łojasiewicz inequality[J]. *Mathematics of operations research*, 2010, 35(2): 438-457.
- [11] Candes E J, Strohmer T, Voroninski V. Phaselift: Exact and stable signal recovery from magnitude measurements via convex programming[J]. *Communications on Pure and Applied Mathematics*, 2013, 66(8): 1241-1274.

- [12] Boyd S, Parikh N, Chu E. Distributed optimization and statistical learning via the alternating direction method of multipliers[M]. Now Publishers Inc, 2011.